

Conjuntos e Lógica *Fuzzy*

Aula 06 – Ajuste do Consequente de um Modelo de Takagi-Sugeno por Quadrados Mínimos.



UNICAMP

Marcos Eduardo Valle
Matemática Aplicada
IMECC - Unicamp



Introdução

Na aula anterior, apresentamos o método de inferência de Takagi-Sugeno para sistemas baseados em regras *fuzzy*.

Introdução

Na aula anterior, apresentamos o método de inferência de Takagi-Sugeno para sistemas baseados em regras *fuzzy*.

Simplificadamente, num modelo de Takagi-Sugeno, os antecedentes são conjuntos *fuzzy* mas os consequentes são funções das variáveis independentes.

Introdução

Na aula anterior, apresentamos o método de inferência de Takagi-Sugeno para sistemas baseados em regras *fuzzy*.

Simplificadamente, num modelo de Takagi-Sugeno, os antecedentes são conjuntos *fuzzy* mas os consequentes são funções das variáveis independentes.

Na aula de hoje, veremos como podemos ajustar as funções do consequente de um modelo de Takagi-Sugeno usando o método dos quadrados mínimos.

Introdução

Na aula anterior, apresentamos o método de inferência de Takagi-Sugeno para sistemas baseados em regras *fuzzy*.

Simplificadamente, num modelo de Takagi-Sugeno, os antecedentes são conjuntos *fuzzy* mas os consequentes são funções das variáveis independentes.

Na aula de hoje, veremos como podemos ajustar as funções do consequente de um modelo de Takagi-Sugeno usando o método dos quadrados mínimos.

Especificamente, veremos como um conjunto de dados numéricos pode ser usado para determinar os parâmetros dos consequentes de um modelo de Takagi-Sugeno de primeira ordem.

Ajuste por Quadrados Mínimos

O método dos quadrados mínimos é uma poderosa ferramenta matemática amplamente utilizado em aprendizado de máquinas, ciências de dados, computação científica e estatística.

Ajuste por Quadrados Mínimos

O método dos quadrados mínimos é uma poderosa ferramenta matemática amplamente utilizado em aprendizado de máquinas, ciências de dados, computação científica e estatística.

O ajuste por quadrados mínimos é usado para encontrar uma função que melhor aproxime um conjunto de dados, minimizando a soma dos quadrados dos erros entre os valores observados e os valores previstos pelo modelo.

Ajuste por Quadrados Mínimos

O método dos quadrados mínimos é uma poderosa ferramenta matemática amplamente utilizado em aprendizado de máquinas, ciências de dados, computação científica e estatística.

O ajuste por quadrados mínimos é usado para encontrar uma função que melhor aproxime um conjunto de dados, minimizando a soma dos quadrados dos erros entre os valores observados e os valores previstos pelo modelo.

Na sequência, revisaremos a metodologia usada na aplicação do método dos quadrados mínimos.

Suponha que temos uma tabela

$\mathbf{x}$	y
$\mathbf{x}_1 = (x_{11}, x_{12}, \dots, x_{1n})$	y_1
$\mathbf{x}_2 = (x_{21}, x_{22}, \dots, x_{2n})$	y_2
$\vdots$	$\vdots$
$\mathbf{x}_m = (x_{m1}, x_{m2}, \dots, x_{mn})$	y_m

que pode ser escrita como $\mathcal{T} = \{(\mathbf{x}_i, y_i) : i = 1, \dots, m\} \subset \mathbb{R}^n \times \mathbb{R}$,
chamado **conjunto de treinamento** em aprendizado de máquinas.

Suponha que temos uma tabela

$\mathbf{x}$	y
$\mathbf{x}_1 = (x_{11}, x_{12}, \dots, x_{1n})$	y_1
$\mathbf{x}_2 = (x_{21}, x_{22}, \dots, x_{2n})$	y_2
$\vdots$	$\vdots$
$\mathbf{x}_m = (x_{m1}, x_{m2}, \dots, x_{mn})$	y_m

que pode ser escrita como $\mathcal{T} = \{(\mathbf{x}_i, y_i) : i = 1, \dots, m\} \subset \mathbb{R}^n \times \mathbb{R}$, chamado **conjunto de treinamento** em aprendizado de máquinas.

Usando funções bases $g_1, \dots, g_L : \mathbb{R}^n \rightarrow \mathbb{R}$ escolhidas *a priori*, defina a função parametrizável $f(\alpha) : \mathbb{R}^n \rightarrow \mathbb{R}$ pela equação

$$f(\alpha)(\mathbf{x}) = \alpha_1 g_1(\mathbf{x}) + \alpha_2 g_2(\mathbf{x}) + \dots + \alpha_L g_L(\mathbf{x}), \quad \forall \mathbf{x} \in \mathbb{R}^n,$$

em que $\mathbf{x} = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$, para $\alpha = (\alpha_1, \dots, \alpha_L) \in \mathbb{R}^L$.

Suponha que temos uma tabela

$\mathbf{x}$	y
$\mathbf{x}_1 = (x_{11}, x_{12}, \dots, x_{1n})$	y_1
$\mathbf{x}_2 = (x_{21}, x_{22}, \dots, x_{2n})$	y_2
$\vdots$	$\vdots$
$\mathbf{x}_m = (x_{m1}, x_{m2}, \dots, x_{mn})$	y_m

que pode ser escrita como $\mathcal{T} = \{(\mathbf{x}_i, y_i) : i = 1, \dots, m\} \subset \mathbb{R}^n \times \mathbb{R}$, chamado **conjunto de treinamento** em aprendizado de máquinas.

Usando funções bases $g_1, \dots, g_L : \mathbb{R}^n \rightarrow \mathbb{R}$ escolhidas *a priori*, defina a função parametrizável $f(\alpha) : \mathbb{R}^n \rightarrow \mathbb{R}$ pela equação

$$f(\alpha)(\mathbf{x}) = \alpha_1 g_1(\mathbf{x}) + \alpha_2 g_2(\mathbf{x}) + \dots + \alpha_L g_L(\mathbf{x}), \quad \forall \mathbf{x} \in \mathbb{R}^n,$$

em que $\mathbf{x} = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$, para $\alpha = (\alpha_1, \dots, \alpha_L) \in \mathbb{R}^L$.

Desejamos encontrar $\alpha_1, \dots, \alpha_L$ de modo que a função f aproxime os dados tabelados, ou seja, $f(\mathbf{x}_i) \approx y_i$, para $i = 1, \dots, m$.

No método dos quadrados mínimos, determinamos $\alpha = (\alpha_1, \dots, \alpha_L)$ que minimiza a soma dos quadrados dos desvios

$$J(\alpha) = \sum_{i=1}^m (y_i - f(\alpha)(\mathbf{x}_i))^2,$$

em que $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{in})$, para todo $i = 1, \dots, m$.

No método dos quadrados mínimos, determinamos $\alpha = (\alpha_1, \dots, \alpha_L)$ que minimiza a soma dos quadrados dos desvios

$$J(\alpha) = \sum_{i=1}^m (y_i - f(\alpha)(\mathbf{x}_i))^2,$$

em que $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{in})$, para todo $i = 1, \dots, m$.

Sendo f linear em α , o problema acima admite a formulação

$$J(\alpha) = \|\mathbf{y} - \mathbf{G}\alpha\|_2^2 \tag{1}$$

em que $\|\cdot\|_2$ denota a norma de Euclídeana,
 $\mathbf{y} = (y_1, \dots, y_m)^T \in \mathbb{R}^m$ e $\mathbf{G} \in \mathbb{R}^{m \times L}$ é a matriz cujas entradas são

$$g_{ij} = g_j(\mathbf{x}_i), \quad \forall i = 1, \dots, m \quad \text{e} \quad j = 1, \dots, L.$$

No método dos quadrados mínimos, determinamos $\alpha = (\alpha_1, \dots, \alpha_L)$ que minimiza a soma dos quadrados dos desvios

$$J(\alpha) = \sum_{i=1}^m (y_i - f(\alpha)(\mathbf{x}_i))^2,$$

em que $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{in})$, para todo $i = 1, \dots, m$.

Sendo f linear em α , o problema acima admite a formulação

$$J(\alpha) = \|\mathbf{y} - \mathbf{G}\alpha\|_2^2 \tag{1}$$

em que $\|\cdot\|_2$ denota a norma de Euclídeana,
 $\mathbf{y} = (y_1, \dots, y_m)^T \in \mathbb{R}^m$ e $\mathbf{G} \in \mathbb{R}^{m \times L}$ é a matriz cujas entradas são

$$g_{ij} = g_j(\mathbf{x}_i), \quad \forall i = 1, \dots, m \quad \text{e} \quad j = 1, \dots, L.$$

Denotamos o problema de quadrados mínimos como $\mathbf{G}\alpha \approx \mathbf{y}$.

A solução de $\mathbf{G}\alpha \approx \mathbf{y}$ pode ser encontrada resolvendo o sistema de equações normais

$$(\mathbf{G}^T \mathbf{G})\alpha = \mathbf{G}^T \mathbf{y},$$

quando as colunas de $\mathbf{G}$ forem linearmente independentes, ou seja, $\mathbf{G}$ tem posto completo e $m \geq L$ (Heath, 2018).

A solução de $\mathbf{G}\alpha \approx \mathbf{y}$ pode ser encontrada resolvendo o sistema de equações normais

$$(\mathbf{G}^T \mathbf{G})\alpha = \mathbf{G}^T \mathbf{y},$$

quando as colunas de $\mathbf{G}$ forem linearmente independentes, ou seja, $\mathbf{G}$ tem posto completo e $m \geq L$ (Heath, 2018).

No caso geral, a solução de quadrados mínimos pode ser obtida utilizando a pseudo-inversa $\mathbf{G}^\dagger$ de $\mathbf{G}$ como segue (Golub and van Loan, 1996; Trefethen and Bau III, 1997):

$$\alpha = \mathbf{G}^\dagger \mathbf{y}.$$

A solução de $\mathbf{G}\alpha \approx \mathbf{y}$ pode ser encontrada resolvendo o sistema de equações normais

$$(\mathbf{G}^T \mathbf{G})\alpha = \mathbf{G}^T \mathbf{y},$$

quando as colunas de $\mathbf{G}$ forem linearmente independentes, ou seja, $\mathbf{G}$ tem posto completo e $m \geq L$ (Heath, 2018).

No caso geral, a solução de quadrados mínimos pode ser obtida utilizando a pseudo-inversa $\mathbf{G}^\dagger$ de $\mathbf{G}$ como segue (Golub and van Loan, 1996; Trefethen and Bau III, 1997):

$$\alpha = \mathbf{G}^\dagger \mathbf{y}.$$

Por fim, a solução de quadrados mínimos também pode ser obtidas utilizando a decomposição QR (Bjorck, 2024).

Regras Fuzzy de Takagi-Sugeno

No modelo de Takagi-Sugeno, as regras são da forma:

SE x_1 é A_{1k} e ... e x_n é A_{nk} , ENTÃO $y = f_k(x_1, \dots, x_n)$,

em que $A_{1k}, \dots, A_{nk}$ são conjuntos *fuzzy* do antecedente da k -ésima regra enquanto o consequente é uma função $f_k : \mathbb{R}^n \rightarrow \mathbb{R}$.

Regras Fuzzy de Takagi-Sugeno

No modelo de Takagi-Sugeno, as regras são da forma:

$$\text{SE } x_1 \text{ é } A_{1k} \text{ e } \dots \text{ e } x_n \text{ é } A_{nk}, \text{ ENTÃO } y = f_k(x_1, \dots, x_n),$$

em que $A_{1k}, \dots, A_{nk}$ são conjuntos *fuzzy* do antecedente da k -ésima regra enquanto o consequente é uma função $f_k : \mathbb{R}^n \rightarrow \mathbb{R}$.

Equivalentemente, podemos escrever a base de regras como

$$\text{SE } \mathbf{x} \text{ é } A_k \text{ ENTÃO } y = f_k(\mathbf{x}), \quad \forall k = 1, \dots, K,$$

em que $\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$ e $A_k \in \mathcal{F}(\mathbb{R}^n)$, com

$$\varphi_{A_k}(\mathbf{x}) = \varphi_{A_{1k}}(x_1) \triangle \varphi_{A_{2k}}(x_2) \triangle \dots \triangle \varphi_{A_{nk}}(x_n),$$

para todo $k = 1, \dots, K$.

Inferência de Takagi-Sugeno

Dada uma entrada $\mathbf{x}$, o modelo de Takagi-Sugeno define uma função $f : \mathbb{R}^n \rightarrow \mathbb{R}$ dada por

$$f(\mathbf{x}) = \frac{\sum_{i=1}^K w_k f_k(\mathbf{x})}{\sum_{\ell=1}^K w_\ell},$$

em que

$$w_k \equiv w_k(\mathbf{x}) = \varphi_{A_k}(\mathbf{x}), \quad \forall k = 1, \dots, K,$$

representam as ativações de cada regra *fuzzy*, que dependem de $\mathbf{x}$. Equivalentemente, podemos escrever

$$f(\mathbf{x}) = \sum_{k=1}^K \bar{w}_k(\mathbf{x}) f_k(\mathbf{x}), \quad \text{em que} \quad \bar{w}_k(\mathbf{x}) = \frac{w_k}{\sum_{\ell=1}^K w_\ell},$$

são as ativações normalizadas, que dependem explicitamente de $\mathbf{x}$.

Takagi-Sugeno de Primeira Ordem

Considere um modelo de Takagi-Sugeno de primeira ordem, ou seja, as funções $f_k : \mathbb{R}^n \rightarrow \mathbb{R}$ são polinômios de primeira ordem:

$$f_k(x_1, \dots, x_n) = a_{k1}x_1 + a_{k2}x_2 + \dots + a_{kn}x_n + b_k = \sum_{j=1}^n a_{kj}x_j + b_k,$$

para todo $k = 1, \dots, K$.

Takagi-Sugeno de Primeira Ordem

Considere um modelo de Takagi-Sugeno de primeira ordem, ou seja, as funções $f_k : \mathbb{R}^n \rightarrow \mathbb{R}$ são polinômios de primeira ordem:

$$f_k(x_1, \dots, x_n) = a_{k1}x_1 + a_{k2}x_2 + \dots + a_{kn}x_n + b_k = \sum_{j=1}^n a_{kj}x_j + b_k,$$

para todo $k = 1, \dots, K$.

Usando as ativações normalizadas, um modelo de Takagi-Sugeno de primeira ordem define a função parametrizada

$$f(\alpha)(\mathbf{x}) = \sum_{k=1}^K \bar{w}_k(\mathbf{x}) \left[\sum_{j=1}^n a_{kj}x_j + b_k \right],$$

em que α é um vetor de parâmetros que contém todos os a_{kj} 's e b_k 's.

Com efeito, podemos escrever

$$f(\alpha)(\mathbf{x}) = \sum_{k=1}^K \sum_{j=1}^n \bar{w}_k(\mathbf{x}) a_{kj} x_j + \bar{w}_k(\mathbf{x}) b_k = \sum_{\ell=1}^L \alpha_{\ell} g_{\ell}(\mathbf{x}),$$

em que

$$\alpha_{\ell} = \begin{cases} a_{kj}, & \ell = (n+1)(k-1) + j, \\ b_k, & \ell = (n+1)k, \end{cases}$$

e

$$g_{\ell}(\mathbf{x}) = \begin{cases} \bar{w}_k(\mathbf{x}) x_j, & \ell = (n+1)(k-1) + j, \\ \bar{w}_k, & \ell = (n+1)k, \end{cases},$$

para $\ell = 1, \dots, L$, com $L = K(n+1)$.

Com efeito, podemos escrever

$$f(\boldsymbol{\alpha})(\mathbf{x}) = \sum_{k=1}^K \sum_{j=1}^n \bar{w}_k(\mathbf{x}) a_{kj} x_j + \bar{w}_k(\mathbf{x}) b_k = \sum_{\ell=1}^L \alpha_{\ell} g_{\ell}(\mathbf{x}),$$

em que

$$\alpha_{\ell} = \begin{cases} a_{kj}, & \ell = (n+1)(k-1) + j, \\ b_k, & \ell = (n+1)k, \end{cases}$$

e

$$g_{\ell}(\mathbf{x}) = \begin{cases} \bar{w}_k(\mathbf{x}) x_j, & \ell = (n+1)(k-1) + j, \\ \bar{w}_k, & \ell = (n+1)k, \end{cases},$$

para $\ell = 1, \dots, L$, com $L = K(n+1)$.

Note que f linear no vetor $\boldsymbol{\alpha}$. Logo, podemos determinar os parâmetros a_{kj} e b_k usando o método dos quadrados mínimos.

Suponha que conhecemos os conjuntos *fuzzy* $A_k \in \mathcal{F}(\mathbb{R}^n)$, $k = 1, \dots, K$ dos antecedentes de um modelo de Takagi-Sugeno de primeira ordem.

Suponha que conhecemos os conjuntos *fuzzy* $A_k \in \mathcal{F}(\mathbb{R}^n)$, $k = 1, \dots, K$ dos antecedentes de um modelo de Takagi-Sugeno de primeira ordem.

Suponha também que temos um conjunto de dados

$$\mathcal{T} = \{(\mathbf{x}_i, y_i) : i = 1, \dots, m\},$$

em que y_i representa a resposta desejada após a observação de $\mathbf{x}_i$, para $i = 1, \dots, m$.

Suponha que conhecemos os conjuntos *fuzzy* $A_k \in \mathcal{F}(\mathbb{R}^n)$, $k = 1, \dots, K$ dos antecedentes de um modelo de Takagi-Sugeno de primeira ordem.

Suponha também que temos um conjunto de dados

$$\mathcal{T} = \{(\mathbf{x}_i, y_i) : i = 1, \dots, m\},$$

em que y_i representa a resposta desejada após a observação de $\mathbf{x}_i$, para $i = 1, \dots, m$.

Usando o método dos quadrados mínimos, os parâmetros do modelo de Takagi-Sugeno podem ser obtidos resolvendo

$$\mathbf{G}\alpha \approx \mathbf{y},$$


em que $\mathbf{G} \in \mathbb{R}^{m \times (n+1)K}$, $\alpha \in \mathbb{R}^{(n+1)K}$ e $\mathbf{y} \in \mathbb{R}^m$ são definidos como segue denotando $\bar{w}_{ki} \equiv \bar{w}_k(\mathbf{x}_i)$, para todo $k = 1, \dots, K$ e $i = 1, \dots, m$.

$$\mathbf{G} = \begin{bmatrix} \bar{w}_{11}x_{11} & \bar{w}_{11}x_{12} & \dots & \bar{w}_{11}x_{1n} & \bar{w}_{11} & \dots & \bar{w}_{K1}x_{11} & \dots & \bar{w}_{K1}x_{1n} & \bar{w}_{K1} \\ \bar{w}_{12}x_{21} & \bar{w}_{12}x_{22} & \dots & \bar{w}_{12}x_{2n} & \bar{w}_{12} & \dots & \bar{w}_{K2}x_{21} & \dots & \bar{w}_{K2}x_{2n} & \bar{w}_{K2} \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & \ddots & \vdots & \vdots \\ \bar{w}_{1m}x_{m1} & \bar{w}_{1m}x_{m2} & \dots & \bar{w}_{1m}x_{mn} & \bar{w}_{1m} & \dots & \bar{w}_{Km}x_{m1} & \dots & \bar{w}_{Km}x_{mn} & \bar{w}_{Km} \end{bmatrix}$$


$$\alpha = \begin{bmatrix} a_{11} \\ a_{12} \\ \vdots \\ a_{1n} \\ b_1 \\ \vdots \\ a_{k1} \\ \vdots \\ a_{kn} \\ b_k \end{bmatrix} \quad \text{e} \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix}.$$

Exemplo – 1

Considere o conjunto de treinamento mostrado abaixo:



Definimos as funções de pertinência:




Usando a metodologia descrita anteriormente, encontramos o modelo de Takagi-Sugeno:

$$\text{SE } x \text{ é } A_1 \text{ ENTÃO } y = 4.79x + 0.08,$$

$$\text{SE } x \text{ é } A_2 \text{ ENTÃO } y = -2.22x + 1.64,$$

$$\text{SE } x \text{ é } A_3 \text{ ENTÃO } y = 7.38x - 5.53.$$


Abaixo o modelo de Takagi-Sugeno com o conjunto de treinamento:



Pode-se observar as retas definidas por cada regra *fuzzy*.

Exemplo – 2

Considere o mesmo conjunto de treinamento mas as funções de pertinência



Neste caso, a metodologia descrita anteriormente fornece o modelo Takagi-Sugeno:

SE x é $C(0.2, 2, 0.15)$ ENTÃO $y = 6.11x - 0.01$,

SE x é $C(0.3, 4, 0.5)$ ENTÃO $y = -1.25x + 1.02$,


SE x é $C(0.2, 2, 0.9)$ ENTÃO $y = 7.84x - 5.89$.

em que

$$C(a, b, c)(x) = \frac{1}{1 + \left| \frac{x-c}{a} \right|^{2b}},$$

é a função de pertinência de Cauchy.


Abaixo o modelo de Takagi-Sugeno com o conjunto de treinamento:




Observe que nesse caso encontramos uma função mais suave que ajusta-se melhor ao conjunto de dados.

Exemplo – 3

Considere o conjunto de treinamento



Considere os conjuntos *fuzzy* abaixo para ambas variáveis x e y :



Usando a metodologia apresentada anteriormente, construímos um modelo de Takagi-Sugeno da forma:

$$\text{SE } x \text{ é } A_1 \text{ e } y \text{ é } A_1 \text{ ENTÃO } y = -0.02x - 0.02y - 0.05,$$


$$\text{SE } x \text{ é } A_1 \text{ e } y \text{ é } A_2 \text{ ENTÃO } y = 0.04x - 0.04,$$

$$\vdots$$

$$\text{SE } x \text{ é } A_3 \text{ e } y \text{ é } A_3 \text{ ENTÃO } y = 0.02x + 0.02y - 0.05,$$


em que o conectivo “e” foi modelado usando o *mínimo*.

Abaixo a superfície obtida usando o modelo de Takagi-Sugeno




Note que o modelo de Takagi-Sugeno apresenta um pico em $(0, 0)$. Além disso, diversas regiões são planas.

Abaixo a superfície da função s cujos dados foram amostrados:



Considere o mesmo conjunto de dados mas os conjuntos *fuzzy* abaixo foram usados para descrever ambas variáveis x e y :



As funções de pertinência são dadas respectivamente por:

$$C(1, 2, -1.5), \quad C(1, 2, 0) \quad \text{e} \quad C(1, 2, 1.5).$$

Usando a mesma metodologia, construímos o seguinte modelo de Takagi-Sugeno:

$$\text{SE } x \text{ é } A_1 \text{ e } y \text{ é } A_1 \text{ ENTÃO } y = -0.28x + 0.28y + 1.08,$$


$$\text{SE } x \text{ é } A_1 \text{ e } y \text{ é } A_2 \text{ ENTÃO } y = -1.04x - 2.42,$$

$$\vdots$$


$$\text{SE } x \text{ é } A_3 \text{ e } y \text{ é } A_3 \text{ ENTÃO } y = -0.28x - 0.28y - 1.08,$$

em que o conectivo “e” foi modelado usando o *produto*.

Abaixo a superfície da função s cujos dados foram amostrados:



Abaixo a superfície obtida usando o modelo de Takagi-Sugeno



A tabela abaixo compara os dois modelos de Takagi-Sugeno considerando diferentes medidas de erro:

	REQM	EAM	EM
Trapézio + Mínimo	6.48×10^{-2}	4.77×10^{-2}	2.81×10^{-1}
Cauchy + Produto	2.51×10^{-2}	1.97×10^{-2}	5.70×10^{-2}

Aqui,

$$REQM = \sqrt{\frac{1}{N} \sum_{j=1}^n (f(x_j, y_j) - s(x_j, y_j))^2},$$

$$EAM = \frac{1}{N} \sum_{j=1}^n |f(x_j, y_j) - s(x_j, y_j)|,$$

$$EM = \max_{j=1:N} \{|f(x_j, y_j) - s(x_j, y_j)|\},$$

em que s e f denotam a função original e o modelo de Takagi-Sugeno. Os pontos (x_j, y_j) , para $j = 1, \dots, N$, foram os mesmos usados para determinar os modelos.

Considerações Finais

Na aula de hoje vimos que o método dos quadrados mínimos pode ser usado para determinar o consequente de um modelo de Takagi-Sugeno de primeira ordem com base num conjunto de dados.

Considerações Finais

Na aula de hoje vimos que o método dos quadrados mínimos pode ser usado para determinar o consequente de um modelo de Takagi-Sugeno de primeira ordem com base num conjunto de dados.

A mesma metodologia pode ser usada para determinar os parâmetros do consequente de um modelo de Takagi-Sugeno de ordem superior ou com outras funções parametrizáveis.

Considerações Finais

Na aula de hoje vimos que o método dos quadrados mínimos pode ser usado para determinar o consequente de um modelo de Takagi-Sugeno de primeira ordem com base num conjunto de dados.

A mesma metodologia pode ser usada para determinar os parâmetros do consequente de um modelo de Takagi-Sugeno de ordem superior ou com outras funções parametrizáveis.

Vimos também que as funções de pertinência de Cauchy, combinadas com a t-norma do produto, apresentam resultados mais suaves que as funções trapezoidais ou triangulares com o mínimo.

Muito grato pela atenção!

References (1)

- A. Bjorck. *Numerical Methods for Least Squares Problems*. Society for Industrial and Applied Mathematics, Philadelphia, PA, second edition, 1 2024. ISBN 978-1-61197-794-3. doi: 10.1137/1.9781611977950.
- G. H. Golub and C. F. van Loan. *Matrix Computations*. John Hopkins University Press, Baltimore, MD, 3th edition, 1996.
- M. T. Heath. *Scientific Computing*. Society for Industrial and Applied Mathematics, Philadelphia, PA, 2nd edition, 11 2018. ISBN 978-1-61197-557-4. doi: 10.1137/1.9781611975581.
- L. N. Trefethen and D. Bau III. *Numerical Linear Algebra*. SIAM Publications, Philadelphia, PA, 1997.